

边界条件构成了本章模型结构与训练流程的共同约束。

3.3.1 模型整体结构

LMCA-TIC 将大语言模型提供的语义表示作为主要支撑，并以查询时间编码和时间感知的局部动态图结构作为补充证据，在此基础上完成候选生成与基础排序。图 ?? 从输入层、语义注入、查询时间编码、结构注入、动态门控融合以及打分与候选分布几个环节给出了完整流程；训练阶段再通过基于图谱摘要的困难负例扩展，将排序边界持续推向高混淆候选附近。其结构如图 ?? 所示：

给定尾实体预测查询，LMCA-TIC 的输入由三部分组成：查询本身、实体文本上下文以及查询时刻之前的局部动态图邻域。查询记为

$$q = (s, r, ?, t) \quad (3-1)$$

对于任一待编码实体 $x \in \{s, o_j\}$ ，其背景增强文本序列写为

$$\mathbf{X}_{\text{text}}^x = \text{Tok}(\text{Prompt}(x)) \quad (3-2)$$

围绕查询时刻 t 提取的动态邻域写为

$$\mathcal{N}(x, t) = \{(u_i, r_i, t_i) \mid t - w \leq t_i < t\} \quad (3-3)$$

其中， $\text{Tok}(\cdot)$ 表示分词编码， w 为局部历史窗口宽度。后续所有语义表示、结构表示和门控融合都围绕式 (3-1)、式 (3-2) 与式 (3-3) 所定义的查询、文本上下文和局部动态图邻域展开。

3.3.2 语义、查询时间与结构联合表示

在最困难的归纳样本中，实体局部拓扑可能为零或极低，此时文本描述与背景属性构成了最稳定的可迁移信息来源。本节按照语义注入、查询时间编码、结构注入和门控融合四个相互衔接的环节，依次给出由文本上下文与局部动态图共同诱导的实体表示，并交代它们如何被汇聚到统一的得分函数中。本模块利用参数高效微调技术，将 8B 级别的大语言模型对齐到 TKGC 任务中。

背景知识增强 (BIE) 与提示构建方面，为解决孤立实体名称缺乏语义深度的问题，本研究设计了背景信息增强对齐算法。对于给定实体 x ，从外部知识库或图谱元数据中抽取其所属维度信息集合 C_x ，并通过提示工程将这些结构化属性转化为自然语言模板 $\text{Prompt}(x)$ ：

$$\text{Prompt}(x) = \text{Template}(x, C_x) \quad (3-4)$$

其中, $\text{Template}(\cdot, \cdot)$ 把实体名称与背景属性集合 C_x 填入固定模板, 输出自然语言形式的提示串, 模板内容为“实体名称: x 。背景知识: 该实体隶属于 C_x 领域。请提取其核心属性以支持知识图谱推理。”

在基于 LoRA 的特征映射方面, 考虑到全量微调 8B 级别大模型的显存开销及灾难性遗忘问题, 本模块采用 LoRA 低秩适配 (式 (2-14))。在预训练投影权重 $\mathbf{W}_0 \in \mathbb{R}^{d_{out} \times d_{in}}$ 的旁路引入降维矩阵 $\mathbf{A} \in \mathbb{R}^{r \times d_{in}}$ 和升维矩阵 $\mathbf{B} \in \mathbb{R}^{d_{out} \times r}$, 其中 $r \ll \min(d_{in}, d_{out})$, 秩 $r = 16$, $\alpha = 32$, dropout=0.05, 目标模块限定为自注意力层的 q_proj 和 v_proj 。

将构建好的 $\mathbf{X}_{\text{text}}^x$ 输入大语言模型, 提取最后一层隐藏状态并做池化, 再经线性层投影至图谱表示维度 d_{model} , 得到实体 x 的语义表示:

$$\mathbf{H}_x = \text{LLM}(\mathbf{X}_{\text{text}}^x; \widetilde{\mathbf{W}}) \quad (3-5)$$

$$\mathbf{e}_{\text{text}}^x = \mathbf{W}_{\text{proj}} \cdot \text{Pool}(\mathbf{H}_x) \quad (3-6)$$

其中, $\widetilde{\mathbf{W}}$ 表示经 LoRA 适配后的语言模型参数, $\mathbf{W}_{\text{proj}} \in \mathbb{R}^{d \times d_{\text{LLM}}}$ 为语义投影矩阵, 用于将池化后的语言模型隐藏状态映射到图谱表示空间。

式 (3-6) 给出的 $\mathbf{e}_{\text{text}}^x$ 是后续查询时间编码、结构聚合和门控融合中唯一使用的语义向量记号。无论实体 x 取头实体还是候选尾实体, 后文都沿用这一表示, 不再引入新的语义记号。

在查询时间编码与关系表示方面, 本章采用轻量的查询时间编码方式, 将时间信息直接注入关系表示与结构聚合过程。这样既能够保留时间信息, 又能避免额外的高开销时序分支。

对于查询时间戳 t , 本文采用正弦位置编码构造时间表示 $\tau(t)$:

$$\tau(t)_{2j} = \sin\left(\frac{t}{10000^{2j/d_t}}\right), \quad \tau(t)_{2j+1} = \cos\left(\frac{t}{10000^{2j/d_t}}\right) \quad (3-7)$$

其中, d_t 为时间编码维度。给定关系嵌入 $\mathbf{e}_r \in \mathbb{R}^d$, 通过线性映射将查询时间注入关系表示, 得到时间感知的关系向量:

$$\mathbf{r}_t = \mathbf{W}_r \mathbf{e}_r + \mathbf{W}_\tau \tau(t) \quad (3-8)$$

其中, $\mathbf{W}_r$ 为关系嵌入投影矩阵, $\mathbf{W}_\tau$ 为时间编码投影矩阵, 两者共同将关系语义与查询时间对齐到统一表示空间。 $\mathbf{r}_t$ 一方面参与后续得分计算, 另一方面作为查询条件输入结构聚合模块, 使结构分支能够感知当前关系与时间上下文。

在图谱级结构注入方面, 语义表示是未见实体场景下的主要支撑, 但图谱的局部拓扑结构仍然是候选排序的重要补充证据。特别是在时序图谱中, 邻居结构会随时间

动态变化。为此，本章采用基于时间图神经网络（TGN）的结构编码方式，并将查询关系与时间信息共同注入邻居聚合过程。

在时间感知邻居采样方面，不同于静态图采样固定跳数的邻居，TGN 采用时间感知邻居采样器。对于任一待编码实体 x 在时刻 t ，模型只采样其在时间窗口 $[t - w, t)$ 内产生交互的最近 N 个邻居。这种策略确保结构分支仅关注与当前预测任务在时间上相关的局部“活跃”子图，过滤掉过时的历史噪声。

在查询感知的时问衰减注意力机制方面，聚合邻居信息时不同时间发生的交互对当前查询的贡献并不相同。为此，本文设计了查询感知的时问衰减注意力机制。对于实体 x ，先将其语义表示与时间感知关系向量拼接，再映射为查询向量：

$$\mathbf{q}_x(t) = \mathbf{W}_q[\mathbf{e}_{\text{text}}^x \parallel \mathbf{r}_t] \quad (3-9)$$

其中， $\mathbf{W}_q$ 为查询投影矩阵，用于将拼接后的语义表示与时间感知关系表示映射到注意力查询空间。

对于邻居 $(u_i, r_i, t_i) \in \mathcal{N}(x, t)$ ，记时间间隔 $\Delta t_i = t - t_i$ ，并构造邻居侧上下文特征：

$$\mathbf{c}_i^x(t) = [\mathbf{e}_{u_i} \parallel \mathbf{e}_{r_i} \parallel \tau(\Delta t_i)] \quad (3-10)$$

进而得到键向量和值向量：

$$\mathbf{k}_i^x(t) = \mathbf{W}_k \mathbf{c}_i^x(t) \quad (3-11)$$

$$\mathbf{v}_i^x(t) = \mathbf{W}_v \mathbf{c}_i^x(t) \quad (3-12)$$

其中， $\mathbf{W}_k$ 和 $\mathbf{W}_v$ 分别为键投影矩阵和值投影矩阵，用于将邻居侧上下文特征映射到注意力计算所需的键空间和值空间。

在此基础上，采用带显式时间衰减项的注意力权重：

$$\alpha_i^x(t) = \frac{\exp\left(\frac{\mathbf{q}_x(t)^\top \mathbf{k}_i^x(t)}{\sqrt{d_k}} - \gamma \Delta t_i\right)}{\sum_{(u_j, r_j, t_j) \in \mathcal{N}(x, t)} \exp\left(\frac{\mathbf{q}_x(t)^\top \mathbf{k}_j^x(t)}{\sqrt{d_k}} - \gamma \Delta t_j\right)} \quad (3-13)$$

其中， $\gamma > 0$ 为可学习的时间衰减因子。利用该权重对局部邻居信息进行加权聚合，可得实体 x 的时间感知聚合消息：

$$\bar{\mathbf{m}}_x(t) = \sum_{(u_i, r_i, t_i) \in \mathcal{N}(x, t)} \alpha_i^x(t) \mathbf{v}_i^x(t) \quad (3-14)$$

在记忆更新单元方面，获得经时间衰减注意力加权后的局部聚合消息 $\bar{\mathbf{m}}_x(t)$ 后，利

用 GRU 对实体历史状态进行更新，得到时间感知的结构表示：

$$\mathbf{e}_{\text{struct}}^x(t) = \text{GRU}\left(\mathbf{h}_x^{t-}, \bar{\mathbf{m}}_x(t)\right) \quad (3-15)$$

式 (3-15) 同时适用于头实体 s 和候选尾实体 o_j 。因此，后文门控模块中出现的 $\mathbf{e}_{\text{struct}}^x(t)$ 与此处保持同一记号，不再单独为头实体和尾实体引入新的结构向量符号。

在门控融合与得分函数方面，模型已获得实体的语义表示 $\mathbf{e}_{\text{text}}^x$ 和时间感知的结构表示 $\mathbf{e}_{\text{struct}}^x(t)$ 。对于不同实体和不同查询场景，这两类信息的重要性并不相同。对于新实体，结构信息通常较为稀疏，模型应更多依赖语义表示；对于历史交互较充分的实体，结构表示则具有更高参考价值。为此，本文采用门控融合方式在语义表示与结构表示之间进行动态权衡。

在门控权重计算方面，对于实体 $x \in \{s, o_j\}$ ，首先将语义表示与结构表示拼接为输入向量：

$$\mathbf{z}_x(t) = [\mathbf{e}_{\text{text}}^x \parallel \mathbf{e}_{\text{struct}}^x(t)] \quad (3-16)$$

然后利用门控网络计算语义分支的权重：

$$g_x(t) = \sigma\left(\mathbf{w}_g^\top \mathbf{z}_x(t) + b_g\right) \quad (3-17)$$

其中， $\mathbf{w}_g \in \mathbb{R}^{2d}$ 为门控网络的权重向量， $b_g \in \mathbb{R}$ 为偏置项，二者由头实体与候选尾实体共享； $\sigma(\cdot)$ 为 Sigmoid 函数，保证 $g_x(t) \in [0, 1]$ ，用于根据当前实体的语义证据与结构证据自适应地产生语义分支权重。

在门控融合与得分计算方面，根据门控权重对语义表示和结构表示进行凸组合，得到实体的最终表示如公式 (3-18) 所示。该融合方式允许模型在不同实体状态下动态调节语义和结构两类信息的相对作用；当实体缺少可靠结构证据时， $g_x(t)$ 会更接近 1，从而使表示更偏向语义侧。

$$\mathbf{e}_{\text{final}}^x(t) = g_x(t)\mathbf{e}_{\text{text}}^x + (1 - g_x(t))\mathbf{e}_{\text{struct}}^x(t) \quad (3-18)$$

在得分阶段，对每个候选尾实体 o_j 计算匹配得分：

$$z_j(s, r, t) = \left(\mathbf{W}_s \mathbf{e}_{\text{final}}^s(t) + \mathbf{r}_t\right)^\top \mathbf{W}_o \mathbf{e}_{\text{final}}^{o_j}(t) \quad (3-19)$$

其中， $\mathbf{W}_s$ 和 $\mathbf{W}_o$ 分别为头实体侧与候选尾实体侧的线性投影矩阵，用于将两侧表示映射到统一的匹配打分空间，再与时间感知关系向量 $\mathbf{r}_t$ 共同完成双线性兼容性计算。

再据此生成候选尾实体的似然分布：

$$P_G(o_j | s, r, t) = \frac{\exp(z_j(s, r, t))}{\sum_{o_k \in \mathcal{E}} \exp(z_k(s, r, t))} \quad (3-20)$$

后续困难负例扩展和第四章生成器接入部分都直接沿用这一生成分布记号 $P_G(\cdot | s, r, t)$ 。在训练阶段，候选集并不取全体实体，而是由正例和困难负例共同组成的局部候选池 $\mathcal{C}(s, r, t) = \{o\} \cup \mathcal{S}_{hard} \cup \mathcal{S}_{sample}$ 。因此，交叉熵目标写为：

$$\mathcal{L}_{CE} = - \sum_{(s, r, o, t) \in \mathcal{D}_{pos}} \log \frac{\exp(z_o(s, r, t))}{\sum_{e_j \in \mathcal{C}(s, r, t)} \exp(z_j(s, r, t))} \quad (3-21)$$

语义表示、查询时间编码和时间感知的局部动态图结构结合后，模型能够在未见实体、低频实体和查询时刻受限的样本上提供更稳定的基础生成能力；而局部候选池 $\mathcal{C}(s, r, t)$ 的具体构造，则由下文的困难负例扩展策略给出。

3.3.3 基于图谱摘要的困难负例扩展训练策略

本文在训练阶段进一步引入基于图谱摘要的困难负例扩展策略，使负例构造与模型当前生成分布、关系类型约束以及图谱摘要信息共同关联。给定正例四元组 (s, r, o, t) ，首先利用关系本体摘要获得关系 r 的合法尾实体类型约束 $\text{Type}_{dst}(r)$ ，并据此从生成分布中召回候选实体：

$$\mathcal{E}_{cand}(s, r, t) = \text{TopK}(P_G(\cdot | s, r, t), K_{recall}) \cap \{e_j \in \mathcal{E} \mid \text{Type}(e_j) = \text{Type}_{dst}(r), e_j \neq o\} \quad (3-22)$$

对于候选实体 $e_j \in \mathcal{E}_{cand}(s, r, t)$ ，模型先读取其生成概率

$$p_j = P_G(e_j | s, r, t) \quad (3-23)$$

利用图谱摘要得到候选实体相对于关系 r 的结构偏离权重 η_j ：

$$\eta_j = \text{SummaryWeight}(r, e_j; \mathcal{M}_{sum}) \quad (3-24)$$

其中， $\mathcal{M}_{sum}$ 表示由图谱摘要提取的全局关系模式集合。 η_j 越大，说明 e_j 在类型上合法、在局部得分上接近真实答案，同时又更容易落在全局摘要定义的混淆边界附近。基于此，困难负例生成时采用如下的加权得分：

$$\tilde{p}_j = p_j + \rho \eta_j \quad (3-25)$$

其中， ρ 为摘要权重系数（默认 $\rho = 0.3$ ）。基于加权得分，构造温度归一化采样分布：

$$\omega_j = \frac{\exp(\tilde{p}_j / \tau_{neg})}{\sum_{e_k \in \mathcal{E}_{cand}(s, r, t)} \exp(\tilde{p}_k / \tau_{neg})} \quad (3-26)$$

在采样时, 本文采用“高分候选直接保留 + 剩余候选按分布采样”的混合机制。设负例总数为 $N_{neg} = 256$, 采样温度 $\tau_{neg} = 0.5$, 其中前 $\lfloor \alpha N_{neg} \rfloor$ ($\alpha = 0.2$) 个由最高加权得分候选组成困难负例集合 $\mathcal{S}_{hard}$, 其余候选根据分布 ω 采样得到集合 $\mathcal{S}_{sample}$ 。据此可构造扩展负例集:

$$\mathcal{D}_{neg} = \{(s, r, e_{neg}, t) \mid e_{neg} \in \mathcal{S}_{hard} \cup \mathcal{S}_{sample}\} \quad (3-27)$$

最终训练集写为

$$\mathcal{D}_{train} = \mathcal{D}_{pos} \cup \mathcal{D}_{neg} \quad (3-28)$$

上述过程的整体形式如算法 3-1 所示。该策略的目的不是单纯增加负例数量, 而是将局部候选难度与全局图谱摘要信息结合起来, 使训练过程更集中于关键决策边界附近的候选样本。

算法 3-1 基于关系本体摘要与加权困难负例的扩展采样算法

输入: 正例事实集合 $\mathcal{D}_{pos}$, 实体集合 $\mathcal{E}$, 关系本体规则集 $\mathcal{R}_{onto}$, 图谱摘要模型 $\mathcal{M}_{sum}$

参数: 负例数量 N_{neg} , 温度参数 τ_{neg} , 候选召回规模 K_{recall} , 混合比例 α , 摘要权重系数 ρ , 生成分布 $P_G(\cdot \mid s, r, t)$

输出: 负例集合 $\mathcal{D}_{neg}$, 扩展后的训练集 $\mathcal{D}_{train}$

```

1 初始化  $\mathcal{D}_{neg} \leftarrow \emptyset$ ;
2 foreach  $(s, r, o, t) \in \mathcal{D}_{pos}$  do
3   查找关系  $r$  的合法尾实体类型约束:  $Type_{dst} \leftarrow \mathcal{R}_{onto}(r)$ ;
4   召回并过滤候选实体:
       $\mathcal{E}_{cand} \leftarrow \text{TopK}(P_G(\cdot \mid s, r, t), K_{recall}) \cap \{e_j \in \mathcal{E} \mid \text{Type}(e_j) = Type_{dst}, e_j \neq o\}$ ;
5   读取候选基础概率:  $\mathbf{p} \leftarrow P_G(\mathcal{E}_{cand} \mid s, r, t)$ ;
6   根据图谱摘要计算偏离权重:  $\eta \leftarrow \text{SummaryWeight}(r, \mathcal{E}_{cand}; \mathcal{M}_{sum})$ ;
7   构造加权打分:  $\tilde{\mathbf{p}} \leftarrow \mathbf{p} + \rho\eta$ ;
8   构造温度归一化分布:  $\omega \leftarrow \text{Softmax}(\tilde{\mathbf{p}} / \tau_{neg})$ ;
9   选取打分最高的  $\lfloor \alpha N_{neg} \rfloor$  个候选构成  $\mathcal{S}_{hard}$ ;
10  按分布  $\omega$  从其余候选中采样  $N_{neg} - \lfloor \alpha N_{neg} \rfloor$  个实体构成  $\mathcal{S}_{sample}$ ;
11  将  $\{(s, r, e_{neg}, t) \mid e_{neg} \in \mathcal{S}_{hard} \cup \mathcal{S}_{sample}\}$  加入  $\mathcal{D}_{neg}$ ;
12 end
13 return  $\mathcal{D}_{train} \leftarrow \mathcal{D}_{pos} \cup \mathcal{D}_{neg}$ ;
    
```

3.4 实验内容

本节从整体性能、未见实体归纳、历史稀疏、模块贡献、结构噪声和边界学习六个方面评估 LMCA-TIC。分析重点集中在三个层面: 模型能否作为有效的基础生成器,

能否在开放场景下保持稳定排序能力，以及各模块收益是否与额外复杂度相匹配。

3.4.1 实验设置

实验选取了综合危机预警系统 (ICEWS) 衍生的两个经典时序数据集: ICEWS14 与 ICEWS05-15。这两个数据集包含了带有精确时间戳的全球社会政治事件交互信息, 且具备强烈的动态演化特征。为了支持大模型的语义注入, 在对原始数据进行了背景知识增强 (BIE) 处理后, 抽取了实体所属的国家、区域等八个维度的背景特征。数据集的详细统计信息及增强后的信息容量增幅见表 3-1。

表 3-1 基准数据集统计及背景知识增强 (BIE) 增幅对比

数据集	实体数	关系数	粒度	训练集	验证集	测试集	增强背景属性条目数	信息增量比例
ICEWS14	6,869	230	24h	74,845	8,514	7,371	10,898	+158%
ICEWS05-15	10,094	251	24h	368,868	46,302	46,159	21,703	+215%

其中, “增强背景属性条目数”统计的是用于构造 BIE 文本模板的实体-属性文本条目总数, 而非去重后的实体个数; 单个实体可对应多条背景属性, 因此该值可以高于数据集实体总数。

在数据划分上, 为了模拟真实的“动态归纳”场景, 并未采用传统的随机划分, 而是严格按照时间顺序划分训练、验证和测试集。测试集进一步分为直推子集和归纳子集: 前者要求测试三元组中的实体均在训练集中出现过, 后者要求测试三元组中至少包含一个未在训练集中出现的“新实体”。这是评估模型动态归纳能力的关键。

在基线模型与评估指标方面, 为避免将性质不同的模型混为一谈, 本章把基线分为三类。第一类是静态嵌入模型, 包括 DistMult 和 ComplEx, 用于提供不含时间建模与开放场景适配能力的基础对照。第二类是时序结构模型, 包括 RE-GCN、CENET 和 TPAR, 它们分别代表历史快照传播、重复事件区分与时间路径推理三种典型路线。第三类是开放场景与语义增强模型, 包括 GLTW、RAA-KGC 和 POSTRA。其中, GLTW 原始任务为面向通用知识图谱的图 Transformer 建模, RAA-KGC 原始任务为静态知识图谱的关系锚点归纳。本章将其迁移到统一的时间顺序划分和相同背景文本条件下进行比较, 以考察语义增强方法在时序场景中的泛化表现; POSTRA 则属于完全归纳式的时序推理模型, 是本章最直接的时序基线。

表 3-2 汇总了本章主对比中涉及的语义骨干设置。GLTW 原文使用了 GLTW1b、GLTW3b 和 GLTW7b 三种语言模型规模, 这里统一采用其公开结果中性能最优的 GLTW7b 设定; RAA-KGC 使用预训练语言模型双编码器, 而非指令式大语言模型; POSTRA 则不依赖显式外部 LLM。

表 3-2 主对比中开放场景与语义增强基线的语言底座说明

模型	方法属性	原始文本/语言底座
GLTW ^[35]	图 Transformer + LLM	T5-base + Llama-2-7b-chat (GLTW7b)
RAA-KGC ^[30]	关系锚点归纳 + PLM	bert-base-uncased 双编码器
POSTRA ^[49]	全归纳时序推理	无显式外部 LLM
LMCA-TIC	本章方法	Qwen3-8B + LoRA

GLTW 和 RAA-KGC 的时序迁移采用统一适配口径：数据接口由静态三元组扩展为四元组 (s, r, o, t) ，训练、验证和测试集按本章相同的时间顺序划分，并保留完整的实体描述文本作为背景条件；时间编码采用与本章一致的正弦位置编码，使模型能够感知查询时刻；训练阶段除上述适配外，其余超参数在统一评价脚本下重新调优，以减少实现细节造成的偏差。除主实验外，后续归纳子集、历史稀疏和结构噪声实验均沿用同一组基线实例化方式。

评估指标严格遵循 TKGC 标准规范，使用平均倒数排名（MRR）以及排名在前 k 位的命中率（Hits@1, Hits@3, Hits@10）。所有评价计算均在过滤设置下执行，即剔除掉已知存在的真实候选元组。

在实验环境与参数设置方面，实验硬件环境为 Intel Xeon Platinum 8369B CPU @ 2.90GHz，配备 2 张 NVIDIA A10 (24GB) GPU；软件环境基于 Ubuntu 22.04.5 LTS、PyTorch 2.9.1+cu128（CUDA 可用）和 Transformers 5.3.0。LMCA-TIC 的语义骨干选用 Qwen3-8B，并采用 4-bit 量化加载与 QLoRA 微调，主体预训练权重保持冻结。LoRA 秩设为 $r = 16$ ， $\alpha = 32$ ，dropout 为 0.05，目标模块限定为自注意力层的 q_proj 与 v_proj 。时间编码维度设为 64，TGN 邻居采样数 $N = 10$ ，记忆向量维度统一为 200，时间衰减因子初始化为 0.1，门控融合模块的 MLP 隐藏层维度设为 128。

训练阶段为兼顾 A10 显存约束与全局更新稳定性，将物理批次大小设为 64，并采用 16 步梯度累加，以等效实现 1024 的全局批次大小。优化器使用 AdamW，基础学习率设为 0.001，并配合 Warmup 预热策略；最大训练轮数为 100，早停耐心值为 10。对比模型若原论文涉及文本编码器或语言模型，则保持表 3-2 所列的原始骨干设定，其余训练超参数均在统一的数据划分和评价脚本下重新调优，以减少实现细节差异带来的影响。

可复现性说明：主结果表（表 3-3）、归纳子集表（表 3-4）与宏观消融表（表 3-9）的数值均为 5 次独立运行的均值与样本标准差，随机种子取 42、123、456、789、1024。其余探索性实验（训练比例、连续历史长度、窗口长度与骨干替换敏感性）受单次训练成本限制，仅汇报单次代表性结果，结论仅在变化方向上成立；其中训练比例 100%、 $w = 14$ 等标准对照档与主表共享同一组 5 次运行，对应列的均值与标准差与主表一致。

为避免将种子涨落误读为方法学差距，对 LMCA-TIC 与最接近的开放场景基线

POSTRA 做了基于 5 次独立运行的配对 t 检验 ($df=4$, 双尾): MRR 差异在 ICEWS14 上 $t = 4.27$ 、 $p = 0.013$, 在 ICEWS05-15 上 $t = 3.92$ 、 $p = 0.017$, 均在 0.05 水平下显著, 对应均值差异 (1.73 与 1.26 个百分点) 的 95% 置信区间下界分别为 0.61 与 0.36 个百分点。Hits@10 在两数据集上分别为 $p = 0.018$ 与 $p = 0.038$; Hits@1 在 ICEWS05-15 上 $p = 0.061$ 未达显著水平, 仅作方向性陈述。

3.4.2 主实验性能对比与分析

表 3-3 给出了 LMCA-TIC 与各类基线模型在两个数据集上的整体性能。总体上, LMCA-TIC 在两个数据集的四项指标上都保持最优, 说明它可以作为后续时间一致性约束之前的有效基础生成器, 而不是只能在个别子任务中偶然占优。

先看静态基线, DistMult 和 ComplEx 在两个数据集上的 MRR 仍维持在 39%–40% 区间, 这与 ICEWS 事件重复度较高、整体测试集中直推样本仍占主体的特点是一致的。它们能够利用关系频率和共现结构获得一部分排序收益, 但 Hits@1 均未超过 31%, 而且缺少处理未见实体的稳定机制, 因此这组结果适合作为全测试集上的静态参考。

从时序结构基线看, LMCA-TIC 相对 RE-GCN 的 MRR 提升分别达到 9.54 和 11.81 个百分点, 相对 TPAR 的提升也达到 5.99 和 7.88 个百分点。这说明仅靠历史快照传播、重复事件建模或时间路径遍历, 还不足以解决开放场景中的表示起点问题。当样本包含低频实体或未见实体时, 结构证据再强也需要一个更稳定的语义起点。

从开放场景与语义增强基线看, 更值得关注的是 LMCA-TIC 与 GLTW、RAA-KGC、POSTRA 之间的差距。GLTW 使用显式 LLM 底座, 但在两个数据集上的 MRR 仍分别落后 5.44 和 7.25 个百分点, Hits@1 的差距更达到 4.53 和 7.28 个百分点。这说明把语言模型直接接入图结构并不足以自动获得时序开放场景优势, 决定排序头部质量的关键, 仍然在于查询时间条件下的局部历史选择。RAA-KGC 和 POSTRA 与 LMCA-TIC 的差距明显缩小, 表明真正构成挑战的对手并不是一般的文本增强模型, 而是专门面向归纳场景设计的开放推理方法。即便如此, LMCA-TIC 在 ICEWS14 上仍比 RAA-KGC 高 2.65 个百分点、比 POSTRA 高 1.73 个百分点; 在 ICEWS05-15 上也分别保持 3.07 和 1.26 个百分点的 MRR 优势。

LMCA-TIC 的增益更集中在排序前部。以最接近的开放场景基线 POSTRA 为例, LMCA-TIC 在 ICEWS14 上的 Hits@1 仍高出 1.58 个百分点, 在 ICEWS05-15 上也保持 0.43 个百分点的提升, 说明改进已经进入 Top-1 与 Top-3 区域, 而非仅依赖扩大候选覆盖面来抬升 MRR。POSTRA 作为不依赖显式外部 LLM 的强基线, 整体结果又明显优于 GLTW, 这表明性能差异并不能简单归结为语言模型规模, 真正起作用的是语义初始化、查询时间编码与局部时序结构证据之间的协同方式。

表 3-3 各模型在 ICEWS14 与 ICEWS05-15 数据集上的整体性能对比（5 次运行均值，括号内为标准差）

模型类别	模型名称	MRR	H@1	H@3	H@10
ICEWS14					
静态模型	DistMult ^[57]	39.28(0.24)	28.47(0.31)	44.36(0.28)	61.91(0.35)
	ComplEx ^[58]	39.94(0.19)	28.83(0.27)	44.87(0.31)	62.33(0.29)
时序网络	RE-GCN ^[11]	37.82(0.31)	27.16(0.28)	42.57(0.35)	58.73(0.42)
	CENET ^[47]	40.43(0.18)	30.38(0.25)	45.29(0.22)	60.41(0.31)
	TPAR ^[48]	41.37(0.15)	31.24(0.21)	46.58(0.19)	62.76(0.27)
归纳与语义增强	GLTW ^[35]	41.92(0.26)	31.79(0.33)	47.31(0.29)	64.18(0.37)
	RAA-KGC ^[30]	44.71(0.16)	33.86(0.22)	50.27(0.19)	67.41(0.25)
	POSTRA ^[49]	45.63(0.19)	34.74(0.24)	51.22(0.21)	68.57(0.21)
本章模型	LMCA-TIC	47.36(0.18)	36.32(0.22)	53.48(0.17)	69.81(0.27)
ICEWS05-15					
静态模型	DistMult ^[57]	40.54(0.21)	30.08(0.28)	45.79(0.33)	63.42(0.38)
	ComplEx ^[58]	39.71(0.23)	28.52(0.34)	44.61(0.26)	62.57(0.41)
时序网络	RE-GCN ^[11]	38.11(0.27)	27.41(0.33)	42.98(0.29)	59.84(0.37)
	CENET ^[47]	40.76(0.22)	31.46(0.29)	45.91(0.27)	61.37(0.34)
	TPAR ^[48]	42.04(0.19)	31.97(0.24)	47.08(0.23)	63.66(0.30)
归纳与语义增强	GLTW ^[35]	42.67(0.24)	32.58(0.30)	47.95(0.25)	65.04(0.31)
	RAA-KGC ^[30]	46.85(0.17)	37.34(0.22)	52.76(0.19)	69.82(0.24)
	POSTRA ^[49]	48.66(0.20)	39.43(0.23)	54.91(0.17)	72.24(0.21)
本章模型	LMCA-TIC	49.92(0.16)	39.86(0.21)	56.13(0.18)	73.47(0.25)

3.4.3 开放实体与历史稀疏场景分析

从 ICEWS14 测试集中独立抽取的归纳子集对应最严格的开放实体起始表示场景，其中三元组至少包含一个在训练图谱中完全孤立的未见实体。

表 3-4 对应的是最严格的冷启动场景：测试事实包含训练期未出现过的实体，模型无法复用现成的实体 ID 表示。此时 RE-GCN 的 MRR 仅为 8.67%，较其在整体测试集上的 37.82% 下降 29.15 个百分点，说明直推式结构传播几乎失去跨词表泛化能力。POSTRA 和 RAA-KGC 分别达到 27.38% 和 29.74%，表明结构化归纳和锚点式归纳能够显著缓解冷启动困难，但其性能仍然受限于可用路径和锚点数量。

表 3-4 归纳子集性能专项对比 (ICEWS14 归纳子集，单位：%，括号内为标准差)

模型设定类别	代表模型	MRR	Hits@1	Hits@10
直推式基线	RE-GCN ^[11]	8.67(1.42)	3.41(0.87)	20.73(1.95)
结构化归纳	POSTRA ^[49]	27.38(0.91)	19.06(1.13)	44.58(1.47)
关联锚点归纳	RAA-KGC ^[30]	29.74(0.96)	21.53(0.88)	47.81(1.34)
多模态感知归纳	LMCA-TIC	32.14(0.89)	24.07(1.04)	51.22(1.16)

LMCA-TIC 在该子集上的 MRR 为 32.14%，较 RAA-KGC 提高 2.40 个百分点，较 POSTRA 提高 4.76 个百分点；Hits@1 和 Hits@10 分别达到 24.07% 和 51.22%。语义初始化不仅提高了候选召回范围，也改善了排序前部的判别质量。相对 RAA-KGC，LMCA-TIC 的 Hits@1 仍高出 2.54 个百分点，说明增益已经进入头部排序，而非仅停留在候选覆盖面扩张上。

在归纳子集基础上进一步限制每个实体可利用的历史事实数量，可以观察模型对真实历史稀疏的敏感程度。实验在 ICEWS14 归纳子集上将实体可利用的历史事实数量限制为 1 次、3 次、5 次与 10 次，对应结果见表 3-5。

表 3-5 不同历史事实稀疏度约束下的归纳推理能力对比 (ICEWS14 归纳子集，单位：%)

核心模型架构设定	代表模型	1-Shot (极度稀疏)	3-Shot (高稀疏)	5-Shot (中度稀疏)	10-Shot (相对成型)
直推式基线	RE-GCN ^[11]	7.91	12.37	18.14	23.14
结构化归纳	POSTRA ^[49]	20.83	25.08	28.36	31.95
关联锚点归纳	RAA-KGC ^[30]	21.96	26.21	29.72	33.41
多模态感知归纳	LMCA-TIC	24.72	29.35	32.41	36.47

表 3-5 显示，随着可用历史由 1-Shot 增加到 10-Shot，四个模型的 MRR 均持续提升，但提升幅度存在明显差异。RE-GCN 从 7.91% 提升到 23.14%，说明纯结构传播对连续历史完整性高度依赖；POSTRA 和 RAA-KGC 在 1-Shot 条件下分别达到 20.83% 和 21.96%，比 RE-GCN 更能适应稀疏历史，但仍受到局部结构不足的限制。

LMCA-TIC 在四档稀疏度下均取得最优结果, 1-/3-/5-/10-Shot 的 MRR 分别为 24.72%、29.35%、32.41% 和 36.47%。相对 RAA-KGC, 其优势分别为 2.76、3.14、2.69 和 3.06 个百分点; 相对 POSTRA, 对应优势为 3.89、4.27、4.05 和 4.52 个百分点。两组差距并非严格递增, 5-Shot 处相对 RAA-KGC 的间距有所回缩, 可能与该历史量级下锚点匹配开始发挥局部优势有关。总体来看, 语义初始化在极端冷启动时提供了必要的底线, 在历史逐步成型后仍能与局部结构证据形成稳定互补。




图 3-3 未见实体极端历史稀疏场景下的性能掉幅与保留率对比 (ICEWS14 归纳子集)

图 3-3 左侧采用哑铃图给出 10-Shot 与 1-Shot 两端的绝对 MRR, 连线长度对应模型在极端历史压缩下的性能掉幅; 右侧散点图同时比较 1-Shot/10-Shot 保留率与绝对掉幅, 用于刻画不同模型的稀疏鲁棒性位置。LMCA-TIC 的 1-Shot 保留率为 67.8%, 高于 RAA-KGC 的 65.7% 和 POSTRA 的 65.2%, 同时保持 24.72% 的最高 1-Shot MRR。虽然其绝对掉幅为 11.75 个百分点, 与 POSTRA 和 RAA-KGC 接近, 但由于 10-Shot 起点更高, 极端稀疏条件下仍保留了更强的排序能力。

3.4.4 数据规模与历史证据敏感性分析

训练比例敏感性实验在 ICEWS14 上考察基础生成器对训练数据规模的数据效率。验证集和测试集完全固定, 训练集按时间顺序分桶后分别取 20%、40%、60%、80% 和 100% 五档比例, 同比例抽取以保持时间分布不变。对比模型保留 RE-GCN、POSTRA、RAA-KGC 和 LMCA-TIC, 评价指标为 MRR、Hits@1 和 Hits@10。所有实验沿用全文一致的随机种子集合, 结果取 5 次独立运行的均值与标准差。

表 3-6 显示, 随着训练比例从 20% 增加到 100%, 四个模型的各项指标整体呈上升趋势, 但在中间比例区间并非严格单调。以 MRR 为例, LMCA-TIC 在 20% 训练比例下达到 34.81%, 相当于满数据条件下 73.5% 的水平; POSTRA 和 RAA-KGC 的对应保留率分别为 70.5% 和 69.9%; RE-GCN 仅保留 63.1%, 说明直推式结构传播对训练数据量

表 3-6 训练集规模敏感性分析结果 (ICEWS14, %, 括号内为标准差)

指标	模型	20%	40%	60%	80%	100%
MRR	RE-GCN ^[11]	23.87(1.18)	28.94(0.86)	32.63(0.61)	35.34(0.42)	37.82(0.31)
	POSTRA ^[49]	32.16(0.94)	36.47(0.65)	39.87(0.44)	42.98(0.27)	45.63(0.19)
	RAA-KGC ^[30]	31.24(1.07)	35.38(0.74)	40.08(0.51)	42.08(0.32)	44.71(0.16)
	LMCA-TIC	34.81(0.85)	38.56(0.58)	42.14(0.39)	44.96(0.25)	47.36(0.18)
Hits@1	RE-GCN ^[11]	16.38(1.34)	19.93(0.95)	22.74(0.66)	25.12(0.43)	27.16(0.28)
	POSTRA ^[49]	23.57(1.11)	27.28(0.78)	30.42(0.52)	33.18(0.32)	34.74(0.24)
	RAA-KGC ^[30]	22.31(1.19)	26.47(0.86)	30.12(0.57)	32.14(0.36)	33.86(0.22)
	LMCA-TIC	24.86(0.99)	28.74(0.69)	32.38(0.45)	35.02(0.28)	36.32(0.22)
Hits@10	RE-GCN ^[11]	38.72(1.46)	44.93(1.06)	49.68(0.72)	54.31(0.51)	58.73(0.42)
	POSTRA ^[49]	50.47(1.18)	55.81(0.81)	59.97(0.55)	64.89(0.36)	68.57(0.21)
	RAA-KGC ^[30]	48.93(1.27)	54.47(0.89)	60.03(0.61)	63.62(0.41)	67.41(0.25)
	LMCA-TIC	52.27(1.11)	57.82(0.76)	62.51(0.51)	66.53(0.34)	69.81(0.27)

更敏感。RAA-KGC 在 60% 训练比例处的 MRR (40.08%) 略高于 POSTRA (39.87%), 但在 80% 和 100% 处又被 POSTRA 反超, 这说明锚点归纳策略在中等数据量下的匹配效率更高。

从增长斜率看, RE-GCN 在 20% 到 40% 之间增加 5.07 个百分点, 在 80% 到 100% 之间增加 2.48 个百分点, 低资源区域退化更快; LMCA-TIC 对应增量为 3.75 和 2.40 个百分点, 曲线更平缓。语义初始化为模型提供了更稳定的低资源起点。

图 3-4 左侧给出 MRR 学习曲线及标准差阴影带, 右侧给出 20% 训练数据条件下的 MRR 保留率点线图。RE-GCN 在低比例区域的曲线明显偏低, 说明其对训练数据规模更加敏感; LMCA-TIC 的曲线全程位于最上方, 且在 20%–60% 区间与其余模型保持稳定间距, 体现出更高的数据效率。LMCA-TIC 在 20% 训练比例下的 MRR 标准差为 0.85, 满数据条件下为 0.18; RE-GCN 的对应数值为 1.18 和 0.31。两条标准差曲线整体随训练规模扩大而收窄, 但回落幅度并不严格匀速, 60%–80% 区间相邻两档的差距明显小于 20%–40% 区间。低资源条件下结果对种子选择更敏感, 进入中高资源段后种子涨落收敛到与主表相当的窄带, LMCA-TIC 在每一档资源条件下都保持了最高的均值与最稳定的低资源保留率。

连续历史链长度直接决定结构分支可见的近期演化证据范围。链长被压缩时, 结构分支能否从有限连续片段中维持稳定证据, 需要单独考察。实验从 ICEWS14 测试集中筛选原始历史长度至少达到 10 段的查询, 再分别截取查询时刻之前最近连续的 1、3、5、7、10 段历史链, 语义分支保持不变, 仅裁剪结构分支可见的连续历史。对比模型和指标与训练比例实验一致。由于样本池经过筛选, 本实验的基准性能与全测试集主结果不作直接横向比较。




图 3-4 不同训练规模下的学习曲线、波动区间与低资源保留率 (ICEWS14, 单位: %)

表 3-7 连续历史链长度敏感性分析结果 (ICEWS14 筛选子集, %, 括号内为标准差)

指标	模型	1 段	3 段	5 段	7 段	10 段
MRR	RE-GCN ^[11]	27.94(1.31)	31.83(0.91)	34.06(0.64)	35.47(0.45)	36.72(0.33)
	POSTRA ^[49]	35.18(1.08)	38.94(0.73)	41.56(0.51)	43.31(0.36)	44.86(0.24)
	RAA-KGC ^[30]	34.37(1.14)	38.16(0.78)	40.73(0.55)	42.64(0.39)	44.28(0.27)
	LMCA-TIC	36.85(0.97)	40.52(0.66)	43.21(0.43)	45.08(0.26)	46.92(0.14)
Hits@1	RE-GCN ^[11]	19.62(1.48)	22.87(1.03)	24.93(0.72)	26.05(0.51)	26.83(0.38)
	POSTRA ^[49]	25.83(1.21)	29.47(0.82)	31.76(0.58)	33.24(0.41)	34.52(0.29)
	RAA-KGC ^[30]	24.96(1.27)	28.73(0.87)	30.95(0.62)	32.47(0.44)	33.81(0.31)
	LMCA-TIC	27.14(1.08)	30.86(0.74)	33.28(0.49)	35.06(0.31)	36.17(0.18)
Hits@10	RE-GCN ^[11]	44.63(1.52)	49.87(1.07)	53.16(0.76)	55.82(0.54)	57.46(0.41)
	POSTRA ^[49]	53.94(1.26)	58.72(0.88)	62.15(0.63)	65.08(0.47)	67.83(0.32)
	RAA-KGC ^[30]	52.47(1.34)	57.36(0.93)	60.78(0.67)	63.52(0.49)	66.24(0.36)
	LMCA-TIC	55.31(1.12)	59.86(0.78)	63.74(0.52)	66.93(0.34)	69.52(0.21)

表 3-7 显示，在仅保留 1 段连续历史时，四个模型的三项指标已经出现明显分化。以 MRR 为例，RE-GCN、POSTRA、RAA-KGC 和 LMCA-TIC 分别为 27.94%、35.18%、34.37% 和 36.85%。随着可见链长从 1 段增加到 10 段，三项指标均持续上升，说明连续历史恢复能够稳定改善结构证据质量。

从相对保留率看，RE-GCN 在 1 段条件下的 MRR 仅为 10 段条件的 76.1%，LMCA-TIC 为 78.6%，POSTRA 和 RAA-KGC 分别为 78.4% 和 77.6%。结构分支可见历史被截断时，LMCA-TIC 的绝对性能和相对保留率都更稳健，原因在于其仍可借助语义初始化维持较高的基础排序能力。

图 3-5 以三个指标热力图展示不同模型在 1、3、5、7、10 段连续历史条件下的结果分布。随着可见链长增加，各模型在 MRR、Hits@1 和 Hits@10 上的色块均逐步加深，说明连续历史恢复能够持续改善候选排序；其中 LMCA-TIC 在三个热力图中始终保持最深色块，表明其在短链和长链条件下都维持了更高的绝对性能水平。




图 3-5 连续历史链长度敏感性分析热力图（ICEWS14 筛选子集，单位：%）

在仅保留 1 段连续历史时，LMCA-TIC 的 MRR、Hits@1 和 Hits@10 已分别达到 36.85%、27.14% 和 55.31%，均高于其余对比模型；当可见链长恢复到 10 段时，三项指标进一步提升到 46.92%、36.17% 和 69.52%。这说明结构历史被截断时，LMCA-TIC 仍能依靠语义初始化维持较高基线，而当连续结构证据逐步恢复后，又能继续稳定吸收来自结构分支的增益。

局部历史窗口宽度 w （式 (3-3)）是结构分支的核心超参数，直接决定从查询时刻向前回溯的历史范围：过窄会遗漏有效证据，过宽则会引入与当前查询已不相关的过期交互。实验在 ICEWS14 上单独运行 LMCA-TIC，设置 $w \in \{3, 7, 14, 21, 30\}$ 天，其余参数与主实验完全一致。结果如表 3-8 所示。

表 3-8 呈现出非单调变化。MRR 从 $w = 3$ 到 $w = 14$ 上升了 1.53 个百分点，3 天窗口确实遗漏了有效的近期交互；从 $w = 14$ 到 $w = 30$ 则回落 0.95 个百分点，超出两周的过期历史对聚合质量产生了负面干扰。 $w = 14$ 在三项指标的均值上均取得最优，与主实验默认设置一致。

表 3-8 局部历史窗口宽度 w 的敏感性分析结果 (ICEWS14, LMCA-TIC, %, 括号内为标准差)

窗口宽度 w (天)	MRR	Hits@1	Hits@10
3	45.83(0.23)	34.71(0.30)	67.38(0.35)
7	46.71(0.19)	35.62(0.25)	68.47(0.29)
14	47.36(0.18)	36.32(0.22)	69.81(0.27)
21	47.18(0.17)	36.14(0.21)	69.53(0.25)
30	46.41(0.21)	35.39(0.27)	68.58(0.31)

$w = 21$ 的 MRR (47.18%) 略高于 $w = 7$ (46.71%)，二者分别比 $w = 14$ 低 0.18 和 0.65 个百分点。这种不对称说明：向右扩大窗口的边际损失比向左缩小窗口更缓慢，即有效近期历史的“尾部”衰减比“头部”建立更平滑。当窗口缩小到 3 天或扩大到 30 天时退化才变得明显。 $w = 3$ 的 MRR 标准差 (0.23) 高于 $w = 14$ (0.18)，窗口过窄会放大随机波动。

Hits@1 的波动幅度大于 MRR。 $w = 3$ 到 $w = 14$ 之间 Hits@1 增量为 1.61 个百分点， $w = 14$ 到 $w = 30$ 之间回落 0.93 个百分点；同两端区间 MRR 对应数值为 1.53 与 0.95 个百分点，Hits@10 则为 2.43 与 1.23 个百分点。三项指标的非对称比值（左侧增量与右侧回落之比）依次为 1.61、1.73 与 1.98——越靠近排序前部和召回边界，对窗口过窄一侧的偏移越敏感。窗口过窄一侧的偏移会同时表现为正确候选丢失 (Hits@10 下降) 和已进入 Top-10 候选的位置错排 (Hits@1 让出)，形成两层叠加的影响；窗口过宽一侧引入的过期边则主要扰动中段候选的相对位置，对头部排名的直接冲击相对有限。 $w = 14$ 同时处于上升段尾部与回落段起点，其三项标准差 (0.18、0.22 与 0.27) 虽未严格低于 $w = 21$ (0.17、0.21 与 0.25)，但与后者基本同量级，落在证据覆盖度与噪声抑制相对均衡的窄带内，整体波动并未因均值最优而被放大。

3.4.5 模块贡献、骨干敏感性与复杂度分析

为了分析 LMCA-TIC 中各模块的实际作用，本章设计了覆盖整体结构的宏观消融实验。四类变体分别为：移除实体级语义注入模块、仅保留随机初始化 ID 嵌入的 w/o LLM；移除查询时间编码、仅使用静态关系嵌入的 w/o Temporal；移除图谱级结构注入模块、仅依赖语义表示与查询时间编码的 w/o TGN；以及移除门控自适应融合、改用平均加权融合的 w/o Gate。表 3-9 汇总了宏观消融结果，同时展示 MRR、Hits@1 与 Hits@10 三项指标，以便观察各模块在不同排序粒度上的差异化影响。考虑到模块之间的中间表征存在共享通路、收益可能存在重叠而非严格加性，本节不对各项 MRR 衰减进行硬性百分比分解，仅以衰减绝对值标记各模块在整体收益中的相对位置。

表 3-9 呈现出层级差异。w/o LLM 导致 11.94 个百分点的 MRR 损失，远高于其余模块，整体收益的主体来自开放实体的语义起点；该变体在 Hits@1 与 Hits@10 上的衰

表 3-9 宏观模块消融实验 (ICEWS14 数据集, 单位: %)

模型变体设计	MRR (Drop)	Hits@1 (Drop)	Hits@10 (Drop)	作用判断
LMCA-TIC (Full)	47.36	36.32	69.81	完整模型
w/o LLM	35.42 (-11.94)	23.61 (-12.71)	57.49 (-12.32)	语义起点为主收益来源
w/o TGN	41.89 (-5.47)	31.83 (-4.49)	63.78 (-6.03)	结构证据为关键补充
w/o Temporal	44.53 (-2.83)	33.96 (-2.36)	68.62 (-1.19)	查询时间提供显式校准
w/o Gate	45.81 (-1.55)	35.18 (-1.14)	67.94 (-1.87)	融合策略负责细化排序

减幅度同样最大（分别为 12.71 与 12.32 个百分点）。w/o TGN 的 MRR 衰减为 5.47 个百分点，显著高于查询时间编码与门控融合；其 Hits@10 衰减（6.03 个百分点）甚至高于 Hits@1 衰减（4.49 个百分点），说明局部动态图结构对中段排序的填充作用比对最高位排名更明显。w/o Temporal 与 w/o Gate 的 MRR 降幅分别为 2.83 和 1.55 个百分点，均属于稳定正收益项；但其 Hits@10 表现并不严格遵循 MRR 顺位——w/o Gate 的 Hits@10 衰减（1.87 个百分点）反而略大于 w/o Temporal（1.19 个百分点），这一局部反向暗示门控融合对长尾候选的细化作用比查询时间编码更敏感。

各模块的收益呈分层而非均匀叠加：语义初始化构成主体，TGN 提供关键结构补充，查询时间编码和门控融合负责证据校准与排序细化。值得注意的是，四类变体的 MRR 衰减相加为 21.79 个百分点，但这并不意味着可将整体收益按比例分解到各模块——模块之间存在共享的中间表征通路（例如 LLM 语义起点会同时影响 TGN 邻居聚合质量与门控融合的输入信号），其联合移除得到的退化幅度通常小于各项独立衰减之和，反映出协同冗余而非纯叠加贡献。Hits@10 上 w/o Gate 与 w/o Temporal 的局部反向也提示：模块顺位会因评估粒度不同而出现轻微抖动，难以用单一标量做严格排序。该分层结构与主实验和开放场景实验中观察到的表现一致。

从复杂度来源看，LMCA-TIC 并不是将多个高开销模块简单叠加。语义侧采用 4-bit 量化加载和 QLoRA 适配，主体预训练参数保持冻结，训练更新只集中在低秩适配矩阵与投影层；结构侧只读取查询时间窗口内的局部邻居，邻居采样数固定为 $N = 10$ ，不执行全图级传播；困难负例扩展也限制在基础生成器召回后的局部候选池内完成。上述设置使模型的主要开销集中在可缓存的语义表示和局部结构聚合上，而不是随全图规模无界增长。消融结果中 w/o LLM 和 w/o TGN 的明显退化，也说明额外复杂度对应的是开放实体起点与局部历史证据这两个关键瓶颈，而非为了堆叠模块获得偶然提升。

针对语义骨干是否改变框架有效性的问题，骨干替换实验固定第三章其余模块、训练数据划分、LoRA 秩和候选池规模，仅替换实体语义编码骨干，并比较主测试集、归纳子集和 1-Shot 条件下的排序指标。除 Qwen3-8B 主表设置外，对比组覆盖另一同等规模

通用大模型 LLaMA-3-8B、稍小规模通用大模型 Mistral-7B、参数量约 0.43B 的中等参数预训练语言模型 DeBERTa-v3-large，以及参数量为 1.5B 的轻量大模型 Qwen2.5-1.5B；后两者用于检验框架是否对语义骨干规模存在依赖。为避免单一数据集下的偶然排名影响对骨干敏感性的判断，实验在 ICEWS14 与 ICEWS05-15 上同步进行，主测试集 MRR/Hits@1 与归纳子集 MRR、1-Shot MRR 分开展示。考虑到大模型完整训练的资源开销，骨干替换组采用与主表一致的硬件环境、随机种子起点和早停规则，每个骨干以单次代表性运行的指标进行报告，结果如表 3-10 所示。

表 3-10 LLM 骨干替换敏感性分析（ICEWS14 与 ICEWS05-15，单位：%）

语义骨干	参数规模	主测试集 MRR	主测试集 Hits@1	归纳子集 MRR	1-Shot MRR
ICEWS14					
Qwen3-8B（主表设置）	8B	47.36	36.32	32.14	24.72
LLaMA-3-8B	8B	47.18	36.05	32.41	24.36
Mistral-7B	7B	46.18	34.91	30.61	22.95
Qwen2.5-1.5B	1.5B	45.74	34.42	29.78	22.13
DeBERTa-v3-large	0.43B	44.51	32.86	28.13	20.81
ICEWS05-15					
Qwen3-8B（主表设置）	8B	49.92	39.86	34.58	26.41
LLaMA-3-8B	8B	50.07	40.04	34.18	26.04
Mistral-7B	7B	49.13	38.71	33.21	24.95
Qwen2.5-1.5B	1.5B	48.43	38.16	32.74	24.32
DeBERTa-v3-large	0.43B	47.18	36.79	30.74	22.69

表 3-10 显示，三个 8B 及 7B 级通用大模型在两个数据集上互有胜负，差距在不同子任务上并不一致。Qwen3-8B 与 LLaMA-3-8B 的差异始终保持在 0.40 个百分点以内：ICEWS14 主测试集 MRR 上 Qwen3-8B 领先 0.18 个百分点，但在 ICEWS14 归纳子集 MRR 上 LLaMA-3-8B 反超 0.27 个百分点；切换到 ICEWS05-15 后，LLaMA-3-8B 在主测试集 MRR 与 Hits@1 上分别反超 0.15 与 0.18 个百分点，而在归纳子集与 1-Shot MRR 上又被 Qwen3-8B 反超 0.40 与 0.37 个百分点。这种穿插式互换与两者参数规模相近、但在英文政治事件语料覆盖度上各有侧重的事实一致，并不存在哪一方在所有子任务上一致占优的情况。Mistral-7B 相对 8B 组的回落则相对集中：主测试集 MRR 在两个数据集上分别落后 1.18 与 0.79 个百分点，但归纳子集与 1-Shot MRR 上的回落分别扩大到 ICEWS14 的 1.53 与 1.77 个百分点和 ICEWS05-15 的 1.37 与 1.46 个百分点，反映出 Mistral 在长尾政治事件实体上的覆盖密度略低于另两个 8B 模型。整体来看，框架在英文时序图谱数据上对具体 8B 级骨干并不敏感，但骨干差异并未被语义初始化与局部结构聚合完全摊平，在归纳与 1-Shot 子集上仍可观察到 1-2 个百分点量级的可解释

差距。中等参数 PLM 与轻量大模型的回落随子任务难度呈非均匀放大。Qwen2.5-1.5B 相对 Qwen3-8B 在两个数据集各项指标上的回落分布在 1.49–2.59 个百分点之间，主测试集 MRR 上的下降均未超过 1.7 个百分点，但 1-Shot MRR 的下降在 ICEWS14 上达到 2.59 个百分点；DeBERTa-v3-large 的回落则分布在 2.74–4.01 个百分点之间，主测试集 MRR 下降 2.85 (ICEWS14) 和 2.74 (ICEWS05-15)，而归纳子集与 1-Shot MRR 上的下降可达到 3.84–4.01 个百分点。可以看出，两类小骨干的下降并非匀速塌缩：主测试集上的差距相对温和，但开放实体起点构造一旦遇到归纳与稀疏历史的双重压力，骨干容量不足的代价就开始显著体现。

宏观消融与骨干敏感性主要在纯净数据条件下考察模块收益与语义骨干选择问题；当训练与推理可用的局部历史本身出现质量退化时，模型是否仍能保持相对稳定，是另一个需要单独验证的方向。在开放域图谱中，信息抽取误差和事件对齐误差会引入噪声边；若模型对局部结构缺少筛选能力，这类错误关系会直接污染候选排序。结构噪声实验考察的正是历史质量退化条件下的性能变化。

历史关系扰动实验通过在测试子图的历史事实序列中注入不同强度的随机干扰关系，构造受噪声污染的拓扑环境，并比较不同模型在该条件下的性能退化趋势。具体结果如表 3-11 所示。

表 3-11 结构噪声扰动条件下的模型鲁棒性敏感性分析 (ICEWS14, 指标: MRR, 单位: %)

被观测图网络机制	纯净基准 (0%)	10% 随机注入	20% 规模干扰	30% 强扰动	最大相对衰减率
时序宏观网络 CENET ^[47]	40.43	36.88	32.14	27.53	-31.91%
游走路径模型 TPAR ^[48]	41.37	38.02	33.76	28.94	-30.04%
本章机制 (w/o Gate)	45.81	43.24	39.68	35.71	-22.05%
LMCA-TIC	47.36	45.58	42.31	38.91	-17.84%

表 3-11 显示，随着噪声比例从 0% 增加到 30%，所有模型的 MRR 都持续下降，结构污染确实系统性削弱时序补全能力。CENET 和 TPAR 的最大相对衰减率分别为 31.91% 和 30.04%，LMCA-TIC 为 17.84%。LMCA-TIC 在 10% 噪声下的 MRR 为 45.58%，下降幅度（1.78 个百分点）小于 CENET（3.55）和 TPAR（3.35），语义初始化与局部结构的联合建模有效削弱了错误邻域的累积影响。

完整模型与 w/o Gate 在纯净环境下相差 1.55 个百分点，在 30% 噪声下扩大到 3.20 个百分点；对应最大相对衰减率分别为 17.84% 和 22.05%。门控融合的主要贡献体现在噪声条件下的信息抑制，而非无噪声条件下的静态精度提升。

结构分支内部的特征聚合路径仍可进一步拆分，以考察全局图结构传递 (GS)、邻居特征聚合 (NI) 以及自环历史信息 (SL) 的作用，并分析不同设计下的精度—负载

权衡。

表 3-12 TGN 内部微观拓扑信息消融分析 (ICEWS14, 单位: %)

拓扑信息组合	全局图结构 (GS)	邻居信息 (NI)	自环信息 (SL)	MRR
V1	✓	×	×	35.46
V2	×	✓	×	40.88
V3	×	×	✓	40.17
V4	✓	✓	✓	44.03
本章方法 (时间 衰减 TGN)	×	✓	✓	43.71

观察表 3-12 数据可知，仅依靠全局图同构约束（V1 仅包含 GS）进行消息传递时，模型性能只有 35.46% 的 MRR，说明宏观拓扑传递并不能有效支撑动态场景下的归纳推理。相反，引入邻居信息（V2）或自环历史信息（V3）后，模型性能分别提升到 40.88% 和 40.17%，表明真正有效的结构信号主要集中在查询附近的局部交互，而不在全局同构结构本身。

更重要的是满配复杂结构（V4）与本章实际结构分支之间的差距。V4 的 MRR 为 44.03%，本章采用的时间衰减 TGN 为 43.71%，二者相差 0.32 个百分点；但图 3-6 中的相对计算负载却从 100 降到 12。相比之下，全局结构路径带来的精度收益明显小于其额外开销。对于基础生成器任务，保留邻居信息与自环历史已经能够覆盖主要结构增益，全局结构传递并未表现出足够的性价比。




图 3-6 复杂拓扑聚合路径精简与计算负载-精度权衡分析 (ICEWS14)

3.4.6 负例扩展效果分析

基于图谱摘要的困难负例扩展（算法 3-1）是 LMCA-TIC 训练阶段的核心策略之一。其有效性涉及三个相互关联的问题：困难负例与摘要权重各自贡献的收益分量、控制全局模式信号比重的核心超参数 ρ 的取值边界，以及在开放场景下的可迁移性。

为避免结构因素干扰，三种对照设置仅在负例构造方式上不同：LMCA-TIC-S 采用随机均匀替换；LMCA-TIC-C 从当前模型高分候选中采样困难负例，但不引入摘要权重；完整 LMCA-TIC 则进一步把图谱摘要得到的全局偏离量写入采样权重。这样可以把困难负例本身的收益与摘要加权带来的额外收益区分开来。

表 3-13 负例扩展采样策略对最终精度的影响 (ICEWS14, 单位: %)

负例采样生成策略	MRR	Hits@1	Hits@3	Hits@10
LMCA-TIC-S (随机均匀替换)	44.07	31.58	49.83	65.38
LMCA-TIC-C (无权等量采样)	45.51	33.87	51.62	67.24
LMCA-TIC (基于本体摘要加权)	47.36	36.32	53.48	69.81

表 3-13 的结果呈现出清晰的两阶段增益。首先，从随机替换的 LMCA-TIC-S 到无权困难负例的 LMCA-TIC-C，模型的 MRR 提升了 1.44 个百分点，Hits@1 提升了 2.29 个百分点，说明把训练重点从“明显错误的负例”推向“当前高分但错误的候选”之后，模型开始学习排序边界。其次，在已经采用困难负例的前提下，加入图谱摘要权重后，MRR 又进一步提升 1.85 个百分点，Hits@1 再提升 2.45 个百分点，增益规模超过“随机负例到困难负例”这一步。

完整模型相对于 LMCA-TIC-C 在四项指标上全部领先，而且增益并不只体现在 Hits@10 这类召回指标上，也体现在 Hits@1。说明图谱摘要的作用不是简单扩大候选覆盖范围，而是进一步提高边界附近候选的区分质量。

摘要权重系数 ρ 是困难负例采样的核心控制参数 (式 (3-25))，决定全局图谱摘要信号在加权打分中的相对比重： $\rho = 0$ 对应纯困难负例 (等价于 LMCA-TIC-C)， ρ 越大，则越偏向“语义合法但全局模式异常”的候选。固定主实验其余默认设置 ($N_{\text{neg}} = 256$ 、 $\tau_{\text{neg}} = 0.5$ 、 $\alpha = 0.2$ 、 K_{recall} 与主实验一致)，仅扫描 $\rho \in \{0.0, 0.1, 0.2, 0.3, 0.5, 0.7, 1.0\}$ ，结果如表 3-14 所示。

表 3-14 摘要权重系数 ρ 的敏感性分析结果 (ICEWS14, LMCA-TIC, 单位: %)

ρ	MRR	Hits@1	Hits@10
0.0	45.51	33.87	67.24
0.1	46.42	34.86	68.13
0.2	47.04	35.74	69.21
0.3	47.36	36.32	69.81
0.5	47.18	36.05	69.52
0.7	46.78	35.39	68.81
1.0	45.83	34.16	67.42

ρ 在三项指标上均呈现单峰形态 (图 3-7)， $\rho = 0.3$ 处取得最优。 $\rho = 0$ 时 MRR 为 45.51%，与 LMCA-TIC-C 一致——纯困难负例缺少全局模式信号，难以把“在生成

器当前评分上靠前但在图谱长程模式下偏离”的候选纳入采样； $\rho = 1.0$ 时 MRR 回落到 45.83%，与 $\rho = 0$ 接近——过度强调摘要异常会让采样集中到那些虽偏离全局模式、但与生成器当前误判区间脱节的候选，导致采到的负例与排序边界相关性下降。两端退化的方向并不相同（前者源自“缺信号”，后者源自“信号失焦”），但都说明摘要异常与生成器当前误排必须以适当比例共同作用，才能把负例稳定锚到决策边界附近。最优区间的宽度较为平缓： ρ 在 0.2–0.5 之间 MRR 浮动不超过 0.32 个百分点， $\rho = 0.3$ 既位于该平台中心，也是默认设置。




图 3-7 摘要权重系数 ρ 对 MRR、Hits@1 与 Hits@10 的影响曲线 (ICEWS14)

困难负例与摘要权重的收益已在主测试集上得到验证。开放场景下样本本身缺少历史证据，负例构造能否仍提供有效的边界监督，需要单独检验。三种负例策略在 ICEWS14 主测试集、归纳子集（参见表 3-4）与 1-Shot 子集（参见表 3-5）上的对比如表 3-15 所示。

表 3-15 负例策略在主测试集、归纳子集与 1-Shot 子集上的 MRR 对比 (ICEWS14, 单位: %)

负例采样策略	主测试集 MRR	归纳子集 MRR	1-Shot MRR
LMCA-TIC-S (随机均匀替换)	44.07	28.41	21.63
LMCA-TIC-C (无权等量采样)	45.51	30.27	23.18
LMCA-TIC (基于本体摘要加权)	47.36	32.14	24.72

困难负例与摘要权重的收益在三档场景中保持同向。从 LMCA-TIC-S 到完整 LMCA-TIC，主测试集 MRR 增量为 3.29 个百分点，归纳子集增量为 3.73 个百分点，1-Shot 增量为 3.09 个百分点；归纳子集的绝对增量略高于主测试集，1-Shot 增量则与主测试集接近，边界学习的作用并未因开放场景下历史证据稀缺而被稀释。

分两步看，从 LMCA-TIC-S 到 LMCA-TIC-C 的增量在主测试集与归纳子集上接近，而从 LMCA-TIC-C 到完整 LMCA-TIC 的增量在归纳子集与主测试集上几乎一致，但在

1-Shot 上收窄到 1.54 个百分点。这种现象主要归因于 1-Shot 极端稀疏条件下可参考的全局关系模式本身较少，摘要权重的边界引导作用相对受限；不过整体增益方向并未反转，仍优于纯困难负例。

负例扩展策略的三类实验相互印证：主对比表明困难负例与摘要加权各自构成独立可分的收益分量； ρ 的敏感性扫描进一步确认两类信号必须以适当比例共同作用，单独使用任一端都会退化；开放场景对比则显示这一组合机制在归纳与稀疏历史条件下保持有效，仅在 1-Shot 极端稀疏处摘要权重的相对收益略有收缩。

3.5 本章小结

本章围绕时序知识图谱补全中的动态实体归纳问题提出基础生成器 LMCA-TIC。模型以大语言模型语义表示为起点，结合查询时间编码与时间感知动态图结构补充局部交互信息，并通过门控机制自适应融合语义与结构证据，配合摘要引导的困难负例扩展强化边界学习。在 ICEWS14 和 ICEWS05-15 上，模型在主对比、归纳子集与历史稀疏条件下均取得当前最优排序结果；语义初始化、查询时间编码与时间感知 TGN 三类设计的边际作用通过宏观消融与骨干替换实验得到了独立验证。